

行业信息研究智能体

数据集建设 / 质量校验 / 可复现评测

面向行业报告与企业资料的可追溯问答系统，将数据规范、证据来源、检索策略与工具执行连接为可验证的工程流程。

代表性成果

100 题

98.6%

96.5%

IndustryBench-100

最终检索 Recall@10

工具选择准确率

四类任务；分层划分

20 题切片 / 18 道可回答

ToolBench-200 / 193 正确

核心工作：从数据到实验

01 数据规范与版本管理

- 构建 IndustryBench-100，包含 40 道事实题、30 道同文档多跳题、20 道跨文档题及 10 道不可答题；开发、验证与测试集分别为 40、30、30 题。
- 维护 Schema、数据哈希和类别配额；记录来源文件、物理页码与证据片段，使数据版本和问题来源可追踪。

02 证据质量与对照评测

- 自动检查字段结构、划分完整性、原文证据定位及重复片段一致性；将表格抽取中的表头、年份与数值关联问题保留为可审阅的修复规则。
- 实现文档范围路由：已知报告优先词法检索，范围未知时融合向量与词法排序。在固定切片上，Recall@10 从 60.6% 提升至 98.6%，Precision@1 从 38.9% 提升至 72.2%。

03 共享工具协议与执行验证

- 运行时与评测共享工具选择策略，分别验收工具选择、参数结构和执行结果；ToolBench-200 选择正确 193/200，Schema 合法 200/200。
- 同模型、同数据的 200 个路由请求，串行与 16 并发的批处理总耗时为 89.1 秒与 8.9 秒。通过有界并发提升同批请求的处理效率。

系统实现与交付成果

研究工作台：基于 React 与 FastAPI 展示问题输入、研究步骤、回答结果与来源证据，支持展开报告片段并核对关键事实。

评测与验证：提供逐题检索统计、工具路由评分和数据配额摘要；核验脚本支持文件哈希检查与统计复算，精选实现包含 16 项通过的离线测试。

作品集材料：一分钟产品流程演示、界面截图、数据工程导读与 26 份精选实现和测试文件。

后续研究方向

完善字段级证据标注、按来源分组的数据划分和困难样本覆盖，结合独立评测分析数据选择与标注质量对模型表现的影响；进一步优化跨文档证据分配与并发调度。

实验设置：检索结果来自固定 20 题切片的 18 道可答题；工具路由使用内部 ToolBench-200。演示为真实前端与归档实验结果回放。